

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT
KHOA HỆ THỐNG THÔNG TIN



HỌC KỲ II: 2025-2026
ĐỒ ÁN CUỐI KỲ
MÔN: GIẢI PHÁP AI TRONG KINH DOANH VÀ QUẢN LÝ

Đề tài: HỆ THỐNG PHÂN TÍCH VÀ TƯ VẤN CHO CÁ NHÂN SỬ
DỤNG DỊCH VỤ BNPL

GVHD: NCS. ThS. NGUYỄN VĂN HỒ
MÃ HỌC PHẦN: 252BIM500602

Tp.HCM, tháng 3 năm 2026

DANH SÁCH THÀNH VIÊN

STT	Họ và Tên	MSSV	Mức độ đóng góp
1	Phan Ngọc Linh	K244020159	100%
2	Bùi Vũ Khánh Phương	K244020187	100%
3	Nguyễn Thị Ngọc Tú	K244020198	100%
4	Nguyễn Điền Xuân Nghi	K244060730	100%
5	Mai Ngọc Thi	K244060743	100%

LỜI CẢM ƠN

Nhóm nghiên cứu xin chân thành cảm ơn thầy Nguyễn Văn Hồ - giảng viên của bộ môn Giải pháp AI trong kinh doanh và quản lý vì đã tạo điều kiện và hỗ trợ cho nhóm chúng em có cơ hội để được nghiên cứu đề tài “*Hệ thống phân tích và tư vấn cho cá nhân sử dụng dịch vụ BNPL*”. Đây là một trải nghiệm học tập và nghiên cứu vô cùng ý nghĩa bởi qua quá trình thực hiện đề tài nghiên cứu này, chúng em có cơ hội vận dụng các kiến thức về trí tuệ nhân tạo, phân tích dữ liệu và xây dựng mô hình hỗ trợ ra quyết định vào một bài toán thực tế trong lĩnh vực tài chính.. Trong quá trình nghiên cứu nhóm chắc chắn sẽ khó tránh khỏi những thiếu sót, kính mong thầy cho chúng em lời nhận xét để từ đó chúng em có cách nhìn toàn diện và sâu sắc hơn trong các vấn đề liên quan tới môn học.

MỤC LỤC

PHẦN 1. GIỚI THIỆU VÀ BỐI CẢNH KINH DOANH	1
1. Bối cảnh ngành và công ty	1
1.1. Tổng quan về hệ thống tài chính số (Fintech).....	1
1.2. Vấn đề kinh doanh và động lực.....	2
1.3. Phạm vi và mô tả dữ liệu.....	2
PHẦN 2. MỤC TIÊU KINH DOANH VÀ CÁC BÊN LIÊN QUAN.....	4
1. Mục tiêu kinh doanh	4
2. Xác định các bên liên quan	4
3. Tác động kinh doanh dự kiến	5
PHẦN 3. ĐỀ XUẤT PHƯƠNG PHÁP VÀ QUY TRÌNH LÀM VIỆC	6
1. Thuật toán tham khảo.....	6
2. Tiền xử lý dữ liệu và xây dựng mô hình.....	6
2.1. Import thư viện.....	6
2.2. Đọc và kiểm tra dữ liệu.....	7
2.3. Chuẩn hóa biến dữ liệu	7
2.4. Mã hóa biến phân loại.....	7
2.5. Tạo thêm đặc trưng	8
2.6. Xây dựng tập đặc trưng.....	8
2.7. Chia tập train/test	9
2.8. Xây dựng và huấn luyện mô hình	9
2.9. Đánh giá mô hình	9
3. Xây dựng hệ thống AI tư vấn.....	10
3.1. Hàm dự đoán rủi ro	10
3.2. Hàm đề xuất số kỳ trả góp	10
3.3. Test hệ thống	10
3.4. Đánh giá mô hình	11
3.5. Kết quả cuối cùng.....	12
4. Đề xuất workflow	14

PHẦN 4. TRIỂN KHAI HỆ THỐNG	16
1. Giao diện các phần.....	16
1.1. Giao diện đăng nhập.....	16
1.2. Giao diện đăng ký	17
1.3. Giao diện nhập thông tin cá nhân.....	18
1.4. Giao diện phân tích	19
2. Kiểm thử hệ thống	20
PHẦN 5. HỖ TRỢ RA QUYẾT ĐỊNH, ĐẠO ĐỨC, CÂN NHẮC TRIỂN KHAI.....	22
1. Sử dụng kết quả trong quản trị.....	22
2. Cân nhắc về đạo đức và rủi ro	22
3. Khả thi và khả năng mở rộng.....	22
PHẦN 6. KẾT LUẬN VÀ LỘ TRÌNH DỰ ÁN	24
DANH MỤC TÀI LIỆU THAM KHẢO	25
PHỤ LỤC	26

DANH MỤC HÌNH ẢNH

Hình 1: Mô hình cho ra kết quả cao nhất	13
Hình 2: Workflow đề xuất của hệ thống.....	14
Hình 3:Màn hình đăng nhập (1)	16
Hình 4: Màn hình đăng ký tài khoản mới (2).....	17
Hình 5: Màn hình nhập các thông tin cá nhân và tài chính cần thiết (3).....	18
Hình 6: Màn hình hiển thị kết quả phân tích (4)	19
Hình 7: Bảng testcase của hệ thống.....	21

PHẦN 1. GIỚI THIỆU VÀ BỐI CẢNH KINH DOANH

1. Bối cảnh ngành và công ty

1.1. Tổng quan về hệ thống tài chính số (Fintech)

Trong những năm gần đây, sự phát triển mạnh mẽ của công nghệ tài chính (Fintech) đã làm thay đổi đáng kể cách cung cấp và sử dụng các dịch vụ tài chính truyền thống. Trong đó Buy Now Pay Later (BNPL) là một hình thức tín dụng ngắn hạn cho phép khách hàng mua hàng trước và thanh toán sau theo nhiều kỳ. Mô hình này ngày càng trở nên phổ biến trong thương mại điện tử nhờ khả năng nâng cao trải nghiệm người dùng và thúc đẩy hành vi mua sắm.

Bên cạnh đó, khái niệm khoản vay vẫn đóng vai trò cốt lõi trong hệ thống tài chính. Dựa trên nghiên cứu "*Loan Default Prediction Using Machine Learning Algorithms*" của các tác giả Zhi Zheng Kang, Sin Yin Teh, Samuel Yong Guang Tan và Wei Chien Ng, khoản vay được hiểu là một hình thức hỗ trợ tài chính từ các tổ chức tài chính nhằm giúp cá nhân giải quyết các thách thức tài chính, đạt được mục tiêu cá nhân hoặc quản lý các chi phí phát sinh ngoài ý muốn. Các cá nhân thường tìm đến khoản vay để thực hiện các mục tiêu cụ thể như mua nhà, tài trợ cho giáo dục, khởi nghiệp hoặc mở rộng kinh doanh, thanh toán các khoản nợ khác.¹

Trong bối cảnh đó, BNPL là một loại hình cho vay ngắn hạn cho phép người mua hàng thanh toán sản phẩm bằng nhiều đợt trả góp nhỏ trải dài trong một khoảng thời gian nhất định. Khác với các loại vay khác, vay mua trước trả sau thường không tính lãi và hiếm khi có các khoản phí dịch vụ khác, rất phù hợp với những người có ngân sách eo hẹp.²

Về mặt vận hành, mô hình BNPL tuân theo một số quy luật đặc trưng liên quan đến hành vi tài chính của người dùng. Cụ thể, thu nhập của khách hàng thường có mối quan hệ tỷ lệ nghịch với số tháng trả nợ, khi những người có thu nhập cao có xu hướng lựa chọn kỳ hạn ngắn hơn, trong khi những người có thu nhập thấp ưu tiên kỳ hạn dài để giảm áp lực tài chính. Ngược lại, số tiền vay có quan hệ tỷ lệ thuận với thời gian trả nợ, khoản vay càng lớn thì kỳ hạn càng dài. Bên cạnh đó, lịch sử tín dụng cũng ảnh hưởng đến mức độ linh hoạt trong đề xuất kỳ hạn, khi khách hàng có lịch sử tốt thường được đưa ra phương án tối ưu hơn.

Ngoài ra, do BNPL phục vụ nhu cầu tiêu dùng nhanh và có quy trình xét duyệt đơn giản, các quyết định thường dựa vào dữ liệu và mô hình để cân bằng giữa trải nghiệm người dùng và rủi ro tín dụng. Mục tiêu chính là tìm ra kỳ hạn phù hợp, vừa đảm bảo khả năng trả nợ vừa hạn chế nợ xấu.

¹ Zhi Zheng Kang, Sin Yin Teh, Samuel Yong Guang Tan và Wei Chien Ng, "*Loan Default Prediction Using Machine Learning Algorithms*", <https://journals.mmupress.com/index.php/jiwc/article/view/1680>, 2025

² Sakshi Udavant, "Buy Now, Pay Later (BNPL): What It Is, How It Works, Pros and Cons", <https://www.investopedia.com/buy-now-pay-later-5182291>, 2025

1.2. Vấn đề kinh doanh và động lực

Mặc dù BNPL mang lại nhiều lợi ích cho cả khách hàng và doanh nghiệp, nhưng mô hình này cũng tồn tại một số vấn đề quan trọng cần được giải quyết.

Thứ nhất, rủi ro vỡ nợ là một trong những thách thức lớn nhất. Khi khách hàng lựa chọn hình thức trả góp, khả năng thanh toán trong tương lai phụ thuộc vào nhiều yếu tố như thu nhập, lịch sử tín dụng, hành vi mua sắm và các điều kiện kinh tế khác. Nếu doanh nghiệp không đánh giá chính xác các yếu tố này, việc cấp tín dụng có thể dẫn đến các khoản nợ xấu.

Thứ hai, việc lựa chọn số kỳ hạn trả góp phù hợp là một bài toán khó đối với cả khách hàng và doanh nghiệp. Nếu số tháng trả góp quá ngắn, số tiền phải thanh toán hàng tháng sẽ cao, gây áp lực tài chính cho khách hàng. Ngược lại, nếu kỳ hạn quá dài, tổng rủi ro tích lũy có thể tăng lên, làm gia tăng khả năng vỡ nợ.

Thứ ba, hiện nay nhiều hệ thống BNPL vẫn chưa cá nhân hóa đủ mạnh. Các phương án trả góp thường được thiết kế theo dạng cố định hoặc dựa trên các quy tắc đơn giản, chưa tận dụng hết tiềm năng của dữ liệu để đưa ra các đề xuất tối ưu cho từng khách hàng cụ thể.

Xuất phát từ những vấn đề trên, việc xây dựng một hệ thống ứng dụng AI nhằm dự đoán rủi ro và đề xuất phương án trả góp tối ưu trở nên cần thiết. Hệ thống này không chỉ giúp doanh nghiệp giảm thiểu rủi ro tài chính mà còn nâng cao trải nghiệm người dùng thông qua việc cung cấp các lựa chọn phù hợp với khả năng chi trả của từng cá nhân.

1.3. Phạm vi và mô tả dữ liệu

Trong phạm vi của đề tài này, nhóm tập trung xây dựng một hệ thống hỗ trợ ra quyết định trong mô hình BNPL với mục tiêu dự đoán xác suất vỡ nợ của khách hàng và đề xuất phương án trả góp tối ưu dựa trên dữ liệu đầu vào.

Trong nghiên cứu này, nhóm sử dụng bộ dữ liệu về hành vi tiêu dùng và khả năng thanh toán của khách hàng trong mô hình Buy Now Pay Later (BNPL). Dataset được tham khảo từ nền tảng Kaggle và được điều chỉnh, làm sạch để phù hợp với mục tiêu nghiên cứu của đề tài. (Nguồn: *BNPL Dataset - Kaggle* -

<https://www.kaggle.com/datasets/bhanageviraj/buy-now-pay-later-bnpl-dataset>)

Sau khi thu thập, nhóm tiến hành chuẩn hóa và lưu trữ dữ liệu dưới dạng file Excel (.csv và.xlsx) nhằm thuận tiện cho quá trình tiền xử lý và huấn luyện mô hình trên môi trường Google Colab.

(Link dataset:

<https://drive.google.com/file/d/12ky6MUFvaYr2Cgu2j3n5l5rYmWm8GpCG/view?usp=sharing>)

Bộ dữ liệu sử dụng trong nghiên cứu có quy mô 50.000 quan sát với 13 biến, được đánh giá là tương đối lớn và có khả năng đảm bảo tính đại diện cho hành vi của khách hàng trong bối cảnh BNPL. Các biến trong dataset được thiết kế đa dạng, phản ánh nhiều khía cạnh khác nhau của người dùng, bao gồm:

- Nhóm thông tin cá nhân:

- Customer_Age: Tuổi của khách hàng
- Gender: Giới tính
- Nhóm thông tin tài chính:
 - Annual_Income: Thu nhập hàng năm
 - Credit_Score: Điểm tín dụng
- Nhóm thông tin giao dịch:
 - Transaction_ID: Mã giao dịch
 - Purchase_Amount: Giá trị đơn hàng
 - Purchase_Category: Loại sản phẩm
- Nhóm hành vi sử dụng hệ thống:
 - Device_Type: Thiết bị sử dụng
 - Browser: Trình duyệt
 - Connection_Type: Loại kết nối mạng
 - Checkout_Time_Seconds: Thời gian hoàn tất thanh toán
- Nhóm thông tin dịch vụ:
 - BNPL_Provider: Nhà cung cấp dịch vụ BNPL

Trong bài toán này, nhóm xác định biến mục tiêu là: Repayment_Status, phản ánh khả năng thanh toán của khách hàng và được chia thành hai nhóm là thanh toán đúng hạn (Paid On Time) và không thanh toán đúng hạn (Defaulted). Do đó, bài toán được xây dựng dưới dạng bài toán phân loại nhị phân (Binary Classification) nhằm dự đoán khả năng trả nợ của khách hàng. Kết quả dự đoán này sẽ được sử dụng làm cơ sở để đề xuất số tháng trả góp phù hợp, góp phần tối ưu hóa rủi ro tín dụng trong hệ thống BNPL.

Nhìn chung, bộ dữ liệu có tính đa chiều và bao quát nhiều yếu tố ảnh hưởng đến hành vi thanh toán của khách hàng, bao gồm cả yếu tố nhân khẩu học, tài chính và hành vi sử dụng dịch vụ. Điều này tạo điều kiện thuận lợi để mô hình học được mối quan hệ giữa khả năng tài chính, hành vi mua sắm và khả năng trả nợ. Tuy nhiên, dataset vẫn tồn tại một số hạn chế nhất định như mang tính mô phỏng nên chưa phản ánh hoàn toàn dữ liệu thực tế, thiếu các biến thể hiện lịch sử tín dụng dài hạn và chưa có dữ liệu theo chuỗi thời gian. Mặc dù vậy, trong phạm vi nghiên cứu của đề tài, bộ dữ liệu này vẫn được đánh giá là phù hợp để xây dựng, huấn luyện và kiểm thử mô hình một cách hiệu quả.

PHẦN 2. MỤC TIÊU KINH DOANH VÀ CÁC BÊN LIÊN QUAN

1. Mục tiêu kinh doanh

Trong bối cảnh mô hình BNPL ngày càng phát triển và cạnh tranh, việc tối ưu hóa hoạt động cấp tín dụng và quản lý rủi ro trở thành yếu tố then chốt đối với doanh nghiệp. Đề tài này hướng đến việc xây dựng một hệ thống hỗ trợ ra quyết định dựa trên trí tuệ nhân tạo, với các mục tiêu kinh doanh cụ thể.

Thứ nhất, giảm thiểu rủi ro vỡ nợ. Thông qua việc áp dụng mô hình học máy để dự đoán xác suất vỡ nợ của khách hàng, hệ thống giúp doanh nghiệp đánh giá chính xác hơn mức độ rủi ro trước khi đưa ra quyết định cho phép trả góp. Điều này góp phần hạn chế các khoản nợ xấu và nâng cao hiệu quả tài chính.

Thứ hai, tối ưu hóa phương án trả góp. Hệ thống không chỉ dừng lại ở việc dự đoán rủi ro mà còn đề xuất các phương án trả góp phù hợp (từ 1 đến 12 tháng), giúp cân bằng giữa khả năng chi trả của khách hàng và mức độ rủi ro chấp nhận được của doanh nghiệp.

Thứ ba, cá nhân hóa trải nghiệm khách hàng. Dựa trên các đặc điểm cá nhân như thu nhập, điểm tín dụng và hành vi mua sắm, hệ thống có khả năng đưa ra các đề xuất phù hợp với từng người dùng, thay vì áp dụng một mô hình chung cho tất cả khách hàng.

Thứ tư, hỗ trợ ra quyết định trong kinh doanh. Kết quả từ hệ thống AI cung cấp thông tin định lượng (xác suất rủi ro, số tiền thanh toán hàng tháng, số kỳ hạn đề xuất), từ đó giúp các nhà quản lý và hệ thống tự động đưa ra quyết định chính xác và nhanh chóng hơn.

2. Xác định các bên liên quan

Trong hệ thống BNPL, có nhiều bên liên quan tham gia và chịu ảnh hưởng trực tiếp hoặc gián tiếp từ các quyết định của hệ thống AI. Việc xác định rõ các bên này giúp đảm bảo hệ thống được thiết kế phù hợp với nhu cầu thực tế.

- Khách hàng (Customer):

Đây là đối tượng trực tiếp sử dụng hệ thống. Khách hàng mong muốn có được các phương án thanh toán linh hoạt, phù hợp với khả năng tài chính cá nhân. Một hệ thống gợi ý chính xác sẽ giúp họ giảm áp lực tài chính và nâng cao trải nghiệm mua sắm.

- Doanh nghiệp cung cấp dịch vụ BNPL:

Đây là bên chịu trách nhiệm cấp tín dụng và quản lý rủi ro. Doanh nghiệp quan tâm đến việc giảm tỷ lệ vỡ nợ, tối ưu lợi nhuận và duy trì sự ổn định tài chính. Hệ thống AI đóng vai trò như một công cụ hỗ trợ ra quyết định hiệu quả.

- Đối tác bán hàng (Merchant):

Các nền tảng thương mại điện tử hoặc cửa hàng bán lẻ sử dụng dịch vụ BNPL để tăng doanh số. Khi khách hàng có nhiều lựa chọn thanh toán hơn, khả năng hoàn tất giao dịch sẽ cao hơn, từ đó mang lại lợi ích trực tiếp cho các đối tác.

- Hệ thống công nghệ (System/Platform):

Đây là nền tảng triển khai các mô hình AI và xử lý dữ liệu. Hệ thống cần đảm bảo tính ổn định, tốc độ xử lý nhanh và khả năng mở rộng để phục vụ lượng lớn người dùng.

3. Tác động kinh doanh dự kiến

Việc triển khai hệ thống AI trong mô hình BNPL được kỳ vọng mang lại nhiều tác động tích cực đối với hoạt động kinh doanh. Trước hết, hệ thống giúp giảm thiểu rủi ro tài chính thông qua việc dự đoán chính xác khả năng vỡ nợ của khách hàng. Điều này giúp doanh nghiệp hạn chế các khoản nợ xấu và tối ưu hóa việc phân bổ nguồn vốn.

Bên cạnh đó, việc cung cấp các phương án trả góp phù hợp sẽ tăng tỷ lệ chuyển đổi. Khi khách hàng được hỗ trợ lựa chọn hình thức thanh toán phù hợp, họ có xu hướng hoàn tất giao dịch nhiều hơn, từ đó góp phần gia tăng doanh thu. Ngoài ra, hệ thống còn giúp nâng cao trải nghiệm người dùng. Việc cá nhân hóa các đề xuất tài chính không chỉ giúp khách hàng cảm thấy thuận tiện mà còn tạo sự tin tưởng đối với dịch vụ.

Cuối cùng, việc ứng dụng AI trong hệ thống BNPL góp phần nâng cao năng lực cạnh tranh của doanh nghiệp trên thị trường. Trong bối cảnh nhiều đối thủ cùng cung cấp dịch vụ tương tự, việc sở hữu một hệ thống thông minh và hiệu quả sẽ là lợi thế quan trọng giúp doanh nghiệp phát triển bền vững.

PHẦN 3. ĐỀ XUẤT PHƯƠNG PHÁP VÀ QUY TRÌNH LÀM VIỆC

1. Thuật toán tham khảo

Trong quá trình xây dựng mô hình, nhóm có tham khảo các phương pháp hiện đại trong lĩnh vực học máy và suy luận nhân quả, tiêu biểu là cách tiếp cận Multi-Treatment Double Machine Learning (DML). Phương pháp này tập trung vào việc ước lượng ảnh hưởng thực sự của các quyết định tài chính (như thay đổi kỳ hạn trả nợ hoặc hạn mức tín dụng) đến kết quả đầu ra, chẳng hạn như khả năng trả nợ của khách hàng. Điểm nổi bật của cách tiếp cận này là không chỉ dừng lại ở việc dự đoán, mà còn hướng đến việc hiểu rõ tác động của từng yếu tố quyết định trong bối cảnh thực tế.³

Tuy nhiên, trong phạm vi triển khai của đề tài, nhóm lựa chọn sử dụng thuật toán LightGBM làm mô hình chính để huấn luyện và dự đoán. Đây là một thuật toán thuộc nhóm boosting có khả năng xử lý dữ liệu lớn, tốc độ huấn luyện nhanh và cho hiệu quả cao trong các bài toán phân loại như dự đoán khả năng vỡ nợ. Mô hình học từ dữ liệu đầu vào bao gồm các đặc trưng về nhân khẩu học, tài chính và hành vi tiêu dùng để dự đoán xác suất khách hàng thanh toán đúng hạn hoặc không.

Dựa trên kết quả dự đoán xác suất rủi ro từ mô hình LightGBM, hệ thống tiến hành xây dựng các phương án trả góp khác nhau bằng cách thay đổi số tháng thanh toán và tính toán mức trả hàng tháng tương ứng. Các phương án này sau đó được so sánh và sắp xếp nhằm đề xuất lựa chọn phù hợp nhất cho từng khách hàng, đảm bảo cân bằng giữa khả năng chi trả và mức độ rủi ro tín dụng.

Mặc dù không triển khai trực tiếp mô hình Multi-Treatment-DML, tư duy về việc đánh giá tác động của các quyết định tài chính vẫn được áp dụng trong quá trình thiết kế hệ thống. Cụ thể, thay vì chỉ đưa ra một kết quả duy nhất, hệ thống cung cấp nhiều phương án để người dùng có thể so sánh và lựa chọn, qua đó tiệm cận với mục tiêu cá nhân hóa quyết định tín dụng. Như vậy, thuật toán LightGBM đóng vai trò là lõi dự đoán trong hệ thống, trong khi các ý tưởng từ suy luận nhân quả được sử dụng như nền tảng định hướng để xây dựng cơ chế đề xuất phương án trả góp một cách hợp lý và thực tiễn hơn.

2. Tiền xử lý dữ liệu và xây dựng mô hình

2.1. Import thư viện

Trong quá trình xây dựng mô hình, nhóm sử dụng các thư viện chính sau:

- *pandas*, *numpy*: xử lý và phân tích dữ liệu
- *scikit-learn*:
 - *train_test_split*: chia dữ liệu
 - *LabelEncoder*: mã hóa dữ liệu dạng chữ
 - *roc_auc_score*: đánh giá mô hình

³ Kexin Zhao¹, Bo Wang¹, Cuiying Zhao¹, Tongyao Wan¹, “Multi-Treatment-DML: Causal Estimation for Multi-Dimensional Continuous Treatments with Monotonicity Constraints in Personal Loan Risk Optimization”, <https://arxiv.org/pdf/2508.02183>, 2025

- *LightGBM*: xây dựng mô hình machine learning. Việc lựa chọn LightGBM giúp tăng tốc độ huấn luyện và cải thiện độ chính xác so với các mô hình truyền thống.

```
import pandas as pd
import numpy as np
```

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import roc_auc_score
```

```
import lightgbm as lgb
```

2.2. Đọc và kiểm tra dữ liệu

```
df = pd.read_csv("bnpl_dataset_v2.csv")
```

Kết quả kiểm tra:

- Kích thước dữ liệu: (50.000, 13). Nghĩa là Dataset gồm 50.000 dòng và 13 cột.

2.3. Chuẩn hóa biến dữ liệu

Biến *Repayment_Status* ban đầu là dạng chữ, được chuyển về dạng số:

```
df['Repayment_Status'] = df['Repayment_Status'].map({
```

```
'Paid On Time':0,
```

```
'Late Payment':1,
```

```
'Defaulted':1
```

```
})
```

Giải thích:

- 0 → Khách hàng trả đúng hạn
- 1 → Khách hàng có rủi ro (trễ hạn hoặc vỡ nợ)

Việc gộp *Late Payment* và *Defaulted* giúp đơn giản hóa bài toán thành phân loại nhị phân, phù hợp với mục tiêu dự đoán rủi ro.

2.4. Mã hóa biến phân loại

Các biến dạng text được chuyển sang dạng số bằng Label Encoding:

```
cat_cols = [
```

```
'Gender',
```

```
'Purchase_Category',
```

```
'BNPL_Provider',
```

```
'Device_Type',
```

```
'Connection_Type',
```

```
'Browser'
```

```
]
```

```
for col in cat_cols:
```

```
    le = LabelEncoder()
```

```
    df[col] = le.fit_transform(df[col])
```

Bước này giúp mô hình machine learning xử lý được dữ liệu dạng categorical với mỗi giá trị text được gán một số nguyên tương ứng.

2.5. Tạo thêm đặc trưng

Nhóm tiến hành tạo thêm các biến mới để tăng khả năng học của mô hình:

1. Số tháng trả góp

```
df['Installment_Months'] = np.random.choice([1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12],  
size=len(df))
```

Sinh ngẫu nhiên số tháng trả góp từ 1 đến 12 để mô phỏng các phương án BNPL.

2. Số tiền trả mỗi tháng

```
df['Monthly_Payment'] = df['Purchase_Amount'] / df['Installment_Months']
```

Thể hiện gánh nặng tài chính hàng tháng.

3. Tỷ lệ trả góp trên thu nhập

```
df['Payment_to_Income'] = df['Monthly_Payment'] / df['Annual_Income']
```

Đây là một đặc trưng rất quan trọng, phản ánh khả năng chi trả của khách hàng và nguy cơ vỡ nợ.

2.6. Xây dựng tập đặc trưng

Tập biến đầu vào của mô hình gồm:

```
features = [
```

```
'Customer_Age',
```

```
'Annual_Income',
```

```
'Credit_Score',
```

```
'Purchase_Amount',
```

```
'Gender',
```

```
'Purchase_Category',
```

```
'BNPL_Provider',
```

```
'Device_Type',
```

```
'Connection_Type',
```

```
'Checkout_Time_Seconds',
```

```
'Browser',
```

```
'Installment_Months',
```

```
'Monthly_Payment',
```

```
'Payment_to_Income'
```

```
]
```

```
X = df[features]
```

```
y = df['Repayment_Status']
```

- *X (input)*: các đặc trưng trên
- *y (target)*: Repayment_Status

2.7. Chia tập train/test

```
X_train, X_test, y_train, y_test = train_test_split(
```

```
X,
```

```
y,
```

```
test_size=0.2,
```

```
random_state=42
```

```
)
```

- 80% dữ liệu dùng để train và 20% dùng để test.
- random_state=42 đảm bảo kết quả có thể tái tập.

2.8. Xây dựng và huấn luyện mô hình

Nhóm sử dụng mô hình LightGBM Classifier

```
model = lgb.LGBMClassifier(
```

```
n_estimators=500,
```

```
learning_rate=0.05,
```

```
max_depth=6
```

```
)
```

```
model.fit(X_train, y_train)
```

- n_estimators=500: số cây decision tree
- learning_rate=0.05: tốc độ học
- max_depth=6: giới hạn độ sâu cây

2.9. Đánh giá mô hình

```
pred = model.predict_proba(X_test)[:,-1]
```

```
auc = roc_auc_score(y_test, pred)
```

Sử dụng ROC - AUC để đánh giá là một metric phù hợp cho bài toán phân loại rủi ro.

AUC càng gần 1 thì mô hình càng tốt

3. Xây dựng hệ thống AI tư vấn

3.1. Hàm dự đoán rủi ro

def predict_default(customer):

Chức năng của hàm chính là nhận thông tin 1 khách hàng và trả về xác suất vỡ nợ

Output:

- Giá trị từ 0 đến 1
- Giá trị càng cao nghĩa là rủi ro càng lớn

3.2. Hàm đề xuất số kỳ trả góp

def recommend_installment(customer, purchase_amount):

Cách hoạt động:

1. Hàm sẽ thử tất cả phương án từ 1 → 12 tháng
2. Các phương án:
 - Tính tiền trả hàng tháng
 - Tính tỷ lệ thu nhập
 - Dự đoán rủi ro
3. Lưu lại kết quả
4. Sắp xếp theo rủi ro tăng dần:

results = sorted(results, key=lambda x: x[2])

Kết quả: Phương án đầu tiên chính là phương án tối ưu nhất.

3.3. Test hệ thống

Để kiểm tra khả năng hoạt động của hệ thống AI trong thực tế, nhóm tiến hành xây dựng một trường hợp kiểm thử với dữ liệu đầu vào đại diện cho một khách hàng cụ thể. Thông tin khách hàng được biểu diễn dưới dạng các biến số phù hợp với định dạng đầu vào của mô hình:

customer = {

'Customer_Age':50,

'Annual_Income':20000000,

'Credit_Score': 900,

'Purchase_Amount':8000000,

'Gender':0,

'Purchase_Category':0,

'BNPL_Provider':2,

'Device_Type':0,

'Connection_Type':1,

'Checkout_Time_Seconds':40,

'Browser':2

}

Dữ liệu này đóng vai trò là đầu vào để hệ thống thực hiện dự đoán và đưa ra tư vấn phương án trả góp.

Sau đó, hệ thống tiến hành gọi hàm để thực hiện quá trình tư vấn:

```
recommend_installment(customer, purchase_amount)
```

Cơ chế hoạt động:

Hàm *recommend_installment* sẽ mô phỏng toàn bộ các phương án trả góp có thể, cụ thể:

- Xét các kỳ hạn từ 1 đến 12 tháng
- Với mỗi kỳ hạn:
 - Tính toán số tiền cần thanh toán mỗi tháng
 - Xác định tỷ lệ thanh toán so với thu nhập
 - Sử dụng mô hình đã huấn luyện để dự đoán xác suất vỡ nợ

Kết quả trả về của mỗi phương án có dạng:

- Số tháng trả góp
- Số tiền phải trả mỗi tháng
- Xác suất vỡ nợ tương ứng

Thực hiện kiểm thử:

Hệ thống được thử nghiệm với nhiều mức giá trị khoản mua khác nhau:

```
recommend_installment(customer, 1000000)
```

```
recommend_installment(customer, 10)
```

Việc thay đổi giá trị khoản mua giúp kiểm tra tính ổn định và khả năng thích ứng của mô hình trong các tình huống khác nhau.

Lựa chọn phương án tối ưu:

Sau khi tính toán tất cả các phương án, hệ thống tiến hành sắp xếp theo mức độ rủi ro tăng dần và lựa chọn phương án tốt nhất:

```
best = recommend_installment(customer, 10000000000)[0]
```

```
print("Recommended installment:", best[0])
```

```
print("Monthly payment:", best[1])
```

```
print("Risk:", best[2])
```

Phương án được lựa chọn là phương án có xác suất vỡ nợ thấp nhất, đảm bảo cân bằng giữa khả năng chi trả của khách hàng và rủi ro tín dụng của hệ thống.

3.4. Đánh giá mô hình

Diễn giải hoạt động của hệ thống tư vấn:

Để minh họa rõ hơn cơ chế hoạt động của hệ thống, nhóm tiến hành gọi hàm AI với một giá trị khoản mua cụ thể. Ví dụ:

```
best = recommend_installment(customer, 20000000000000)[0]
```

```
print("Recommended installment:", best[0])
```

```
print("Monthly payment:", best[1])
```

```
print("Risk:", best[2])
```

Trong đoạn mã trên, hệ thống sử dụng hàm *recommend_installment* để tính toán và đánh giá toàn bộ các phương án trả góp cho một khoản mua hàng.

- Hệ thống sẽ mô phỏng các phương án trả góp từ 1 đến 12 tháng
- Với mỗi phương án, mô hình sẽ:
 - Tính toán số tiền cần trả mỗi tháng
 - Đánh giá mức độ phù hợp với thu nhập khách hàng
 - Dự đoán xác suất vỡ nợ thông qua mô hình đã huấn luyện

Kết quả trả về của mỗi phương án có dạng:

- Số tháng trả góp
- Số tiền phải trả mỗi tháng
- Xác suất vỡ nợ tương ứng

Phương án được chọn là phương án có xác suất vỡ nợ thấp nhất, đảm bảo giảm thiểu rủi ro tín dụng và phù hợp với khả năng chi trả của khách hàng.

```
best = recommend_installment(customer, 2000000000000)[0]
```

3.5. Kết quả cuối cùng

Để đánh giá hiệu quả của mô hình phân loại, nhóm sử dụng đường cong ROC (Receiver Operating Characteristic).

```
from sklearn.metrics import roc_curve, auc
import matplotlib.pyplot as plt
```

```
# y_test: nhãn thật
```

```
# y_pred_prob: xác suất dự đoán của model
```

```
y_pred_prob = model.predict_proba(X_test)[: , 1]
```

```
fpr, tpr, thresholds = roc_curve(y_test, y_pred_prob)
```

```
roc_auc = auc(fpr, tpr)
```

```
plt.figure()
```

```
plt.plot(fpr, tpr, label="ROC curve (AUC = %0.4f)" % roc_auc)
```

```
plt.plot([0, 1], [0, 1], linestyle="--") # đường random
```


```
plt.xlabel("False Positive Rate")
```

```
plt.ylabel("True Positive Rate")
```

```
plt.title("ROC Curve")
```


```
plt.legend(loc="lower right")
```

```
plt.show()
```



Hình 1: Mô hình cho ra kết quả cao nhất

4. Đề xuất workflow



Hình 2: Workflow đề xuất của hệ thống

Quy trình AI trong hệ thống Buy Now Pay Later (BNPL) được thiết kế như một chuỗi xử lý khép kín, liên kết chặt chẽ giữa Frontend (FE), Backend (BE), AI Risk Model và Database, qua đó chuyển hóa dữ liệu thành quyết định tín dụng mang tính cá nhân hóa và có kiểm soát rủi ro. Dưới góc nhìn kinh doanh, toàn bộ workflow không chỉ là một pipeline kỹ thuật mà là một hệ thống ra quyết định thông minh, nơi mỗi thành phần đóng một vai trò cụ thể nhưng đồng thời phụ thuộc lẫn nhau để tối ưu hóa mục tiêu kép: gia tăng tỷ lệ chuyển đổi và giảm thiểu nợ xấu. Quy trình bắt đầu từ Frontend khi khách hàng lựa chọn phương thức thanh toán BNPL và cung cấp các thông tin cần thiết như dữ liệu định danh, thông tin đơn hàng và hành vi cơ bản; hành động này kích hoạt một API request (POST /bnpl/apply) gửi về Backend, đánh dấu điểm chuyển giao từ tương tác người dùng sang xử lý hệ thống. Tuy nhiên, về bản chất, đây không đơn thuần là một yêu cầu giao dịch mà là điểm khởi đầu của bài toán kinh doanh cốt lõi: xác định mức độ tín nhiệm của khách hàng và thiết kế phương án thanh toán phù hợp thay vì áp dụng các gói cố định thiếu linh hoạt như các mô hình BNPL truyền thống.

Tại Backend, dữ liệu đầu vào được xử lý qua nhiều lớp nhằm đảm bảo tính chính xác và khả năng khai thác cho mô hình AI. Trước hết là bước kiểm tra và xác thực dữ liệu nhằm phát hiện sai lệch hoặc dấu hiệu gian lận, qua đó giảm thiểu rủi ro ngay từ đầu vào; tiếp theo, hệ thống thực hiện truy vấn dữ liệu lịch sử từ Database bao gồm thông tin khách hàng, lịch sử giao dịch và lịch sử thanh toán, cho phép mở rộng góc nhìn từ dữ liệu tức

thời sang hành vi tài chính dài hạn. Sau đó, dữ liệu được chuẩn hóa và chuyển sang giai đoạn Feature Engineering, nơi các biến đầu vào có ý nghĩa dự báo được xây dựng như số lần trễ hạn, tần suất mua hàng, tỷ lệ hoàn thành thanh toán và tuổi tài khoản; đây là bước mang tính quyết định vì nó thể hiện sự kết hợp giữa hiểu biết nghiệp vụ tài chính và kỹ thuật xử lý dữ liệu, tạo nền tảng cho mô hình học máy hoạt động hiệu quả. Khi dữ liệu đã được xử lý hoàn chỉnh, chúng được đưa vào khối AI Risk Model, nơi mô hình LightGBM được sử dụng để dự đoán xác suất trễ hạn và vỡ nợ của từng khách hàng; việc lựa chọn mô hình này phản ánh sự phù hợp với dữ liệu dạng bảng và yêu cầu triển khai thực tế nhờ khả năng xử lý nhanh, hiệu quả và tương đối dễ diễn giải. Kết quả đầu ra của mô hình không tồn tại dưới dạng rời rạc mà được tổng hợp thành một chỉ số Risk Score, đóng vai trò như một thước đo định lượng mức độ rủi ro, giúp đơn giản hóa quá trình ra quyết định ở tầng nghiệp vụ.


Việc đánh giá mô hình trong hệ thống này không dừng lại ở các chỉ số kỹ thuật như AUC hay Precision–Recall mà được đặt trong bối cảnh tác động kinh doanh, tức là mô hình chỉ được xem là hiệu quả khi đồng thời giảm được tỷ lệ nợ xấu mà không làm suy giảm đáng kể tỷ lệ duyệt giao dịch. Điều này dẫn đến việc tích hợp kết quả mô hình vào Decision Engine tại Backend, nơi Risk Score được chuyển hóa thành các quyết định cụ thể theo từng mức rủi ro, bao gồm duyệt hoàn toàn đối với nhóm rủi ro thấp, duyệt có điều kiện đối với nhóm trung bình và từ chối hoặc đề xuất phương án thay thế đối với nhóm rủi ro cao. Tuy nhiên, điểm khác biệt cốt lõi của hệ thống không nằm ở việc phân loại khách hàng mà ở khả năng tối ưu hóa phương án thanh toán; cụ thể, dựa trên kết quả dự đoán, hệ thống tiếp tục phân tích khả năng chi trả để đề xuất số tháng trả góp phù hợp, qua đó giảm xác suất trễ hạn hoặc vỡ nợ trong tương lai. Quyết định cuối cùng sau đó được trả về Frontend để hiển thị cho người dùng, đồng thời toàn bộ dữ liệu liên quan đến dự đoán, quyết định và hành vi thực tế được lưu trữ lại trong Database, tạo thành một vòng lặp phản hồi (feedback loop) giúp hệ thống liên tục học hỏi và cải thiện theo thời gian.

Tổng thể, workflow này thể hiện một kiến trúc tích hợp giữa FE, BE, AI và Database, trong đó Backend đóng vai trò trung tâm điều phối, AI đóng vai trò phân tích và dự báo, còn Database đảm bảo tính liên tục và khả năng học thích nghi của hệ thống; sự kết hợp này không chỉ giúp nâng cao độ chính xác trong đánh giá rủi ro mà còn chuyển đổi cách thức ra quyết định từ kinh nghiệm sang dựa trên dữ liệu, từ đó tạo nền tảng cho một hệ thống BNPL thông minh, linh hoạt và bền vững hơn trong dài hạn.

PHẦN 4. TRIỂN KHAI HỆ THỐNG

1. Giao diện các phần

1.1. Giao diện đăng nhập



The image shows a login window titled "python" with standard window controls. The login form is centered and contains the following elements:

- A header bar with a yellow padlock icon and the text "Đăng nhập".
- A light blue bar with the text "Chào mừng bạn quay lại".
- A "Username" input field with a person icon.
- A "Password" input field with a yellow padlock icon.
- A blue "Đăng nhập" button.
- A link "Chưa có tài khoản? Đăng ký" at the bottom.

Hình 3:Màn hình đăng nhập (1)

1.2. Giao diện đăng ký

python

Đăng ký tài khoản

Tạo tài khoản để tiếp tục

Username

Password

Confirm Password

Tạo tài khoản

Đã có tài khoản? [Đăng nhập](#)

Hình 4: Màn hình đăng ký tài khoản mới (2)

1.3. Giao diện nhập thông tin cá nhân

 **Nhập thông tin khách hàng**

Tuổi	Tuổi	Thu nhập	Thu nhập
Credit Score	Credit Score	Số tiền	Số tiền mua hàng hàng ngày
Checkout	Checkout (s)	Giới tính	Nam
Danh mục	Electronics	Provider	Klarna
Thiết bị	Mobile	Kết nối	WiFi
Browser	Chrome		

Next →

Hình 5: Màn hình nhập các thông tin cá nhân và tài chính cần thiết (3)

1.4. Giao diện phân tích

Phân tích trả góp

AI đề xuất phương án thanh toán tối ưu

7,0000 Phân tích

TOP PHƯƠNG ÁN TỐT NHẤT

1. 6 tháng
11,667 USD / tháng
Risk: 0.9134
2. 12 tháng
5,833 USD / tháng
Risk: 0.9271
3. 9 tháng
7,778 USD / tháng
Risk: 0.9319
4. 7 tháng
10,000 USD / tháng
Risk: 0.9788
5. 8 tháng
8,750 USD / tháng
Risk: 0.9788

Hình 6: Màn hình hiển thị kết quả phân tích (4)

Hệ thống được thiết kế với cơ sở dữ liệu gồm ba bảng chính: User, Information và Predict. Trong đó, bảng User dùng để lưu trữ thông tin tài khoản đăng nhập của người dùng, bảng Information để lưu các thông tin cá nhân phục vụ cho quá trình phân tích và bảng Predict dùng để ghi nhận kết quả dự đoán do mô hình AI tạo ra.

Về luồng hoạt động, tại trang *Màn hình đăng nhập (1)*, khi người dùng nhập username và password, hệ thống sẽ gửi yêu cầu đến bảng User để kiểm tra tính hợp lệ của tài khoản. Nếu thông tin đăng nhập không tồn tại, người dùng sẽ được chuyển hướng sang *Màn hình đăng ký tài khoản mới (2)* để thực hiện các bước tạo tài khoản mới. Sau khi hoàn tất đăng ký, người dùng quay lại trang đăng nhập và tiến hành đăng nhập vào hệ thống.

Tiếp theo tại trang *Màn hình nhập các thông tin cá nhân và tài chính cần thiết (3)*, người dùng sẽ cung cấp các dữ liệu cá nhân cần thiết, những thông tin này sẽ được lưu vào bảng Information. Sau đó, tại bước phân tích, người dùng nhập các thông tin liên quan đến khoản vay hoặc số tiền cần đánh giá. Hệ thống sẽ sử dụng dữ liệu này để gọi hàm và

checkpoint của AI đã được huấn luyện sẵn để thực hiện quá trình dự đoán và trả về kết quả.

Kết quả dự đoán sau đó được lưu vào bảng Predict, đồng thời hiển thị trực tiếp lên giao diện người dùng để hỗ trợ ra quyết định. Toàn bộ hệ thống được xây dựng dựa trên công nghệ PyQt6 cho phần giao diện người dùng và MongoDB cho việc lưu trữ dữ liệu để đảm bảo tính linh hoạt và khả năng mở rộng trong quá trình triển khai.

2. Kiểm thử hệ thống

TR_ID	Test requirement	Precondition	ID Test Case	Description	Test steps	Expected result	Status	Bug ID	Tester	Tested date	Remark
REG	Đăng ký		REG_001	Đăng ký với dữ liệu hợp lệ	1. Nhập Username 2. Nhập mật khẩu hợp lệ 3. Nhập lại mật khẩu hợp lệ 4. Nhấn "Tạo tài khoản"	Hệ thống tạo tài khoản mới và hiển thị thông báo đăng ký thành công	Okce		Thi	27/3/2026	
			REG_002	Nhập lại sai mật khẩu	1. Nhập Username 2. Nhập mật khẩu hợp lệ 3. Nhập lại mật khẩu không hợp lệ 4. Nhấn "Tạo tài khoản"	Hệ thống hiển thị lỗi "Mật khẩu không khớp!"	Okce		Thi		
			REG_003	Mật khẩu quá ngắn	1. Nhập Username 2. Nhập mật khẩu ngắn 3. Nhấn "Tạo tài khoản"	Hệ thống hiển thị lỗi "Password phải >= 4 ký tự!"			Thi		
LOGIN	Đăng nhập		LOGIN_001	Đăng nhập với thông tin đúng	1. Nhập email hợp lệ 2. Nhập mật khẩu đúng 3. Nhấn "Đăng nhập"	Hệ thống đăng nhập thành công và chuyển đến trang chính	Okce		Thi		
			LOGIN_002	Nhập sai mật khẩu	1. Nhập email đúng 2. Nhập mật khẩu sai 3. Nhấn "Đăng nhập"	Hệ thống hiển thị lỗi "Sai mật khẩu" và không cho đăng nhập	Okce		Thi		
			LOGIN_003	Tài khoản chưa đăng ký	1. Nhập email chưa đăng ký 2. Nhập mật khẩu bất kỳ 3. Nhấn "Đăng nhập"	Hệ thống hiển thị lỗi "Tài khoản không tồn tại"	Chỉ hiển thị sai tài khoản haoc85 mật khẩu thôi		Thi		
			LOGIN_004	Không nhập dữ liệu	1. Để trống email và mật khẩu 2. Nhấn "Đăng nhập"	Hệ thống hiển thị lỗi yêu cầu nhập đầy đủ thông tin					
ID	Transaction ID		ID_001	Transaction ID hợp lệ	Nhập Transaction ID hợp lệ	Hệ thống lưu dữ liệu thành công và không phát hiện trùng lặp	Okce		Thi		
			ID_002	Transaction ID trùng	Nhập Transaction ID đã tồn tại	Hệ thống hiển thị lỗi trùng ID và không lưu dữ liệu	Okce		Thi		
			ID_003	Transaction ID rỗng	Để trống Transaction ID	Hệ thống hiển thị lỗi bắt buộc nhập trường này	Okce		Thi		
AGE	Tuổi		AGE_001	Tuổi hợp lệ	Nhập tuổi hợp lệ	Hệ thống chấp nhận và xử lý dữ liệu bình thường	Okce		Thi		
			AGE_002	Tuổi âm	Nhập tuổi âm	Hệ thống hiển thị lỗi "Tuổi không hợp lệ"	Okce		Thi		
			AGE_003	Tuổi vượt giới hạn	Nhập tuổi > 100	Hệ thống hiển thị lỗi vượt giới hạn cho phép	Okce		Thi		
GEN	Giới tính		GEN_001	Giới tính hợp lệ	Chọn giới tính hợp lệ	Hệ thống chấp nhận giá trị và lưu dữ liệu	Okce		Thi		
			GEN_002	Giới tính rỗng	Không chọn giới tính	Hệ thống hiển thị lỗi bắt buộc chọn	Giới tính đã đc chọn sẵn		Thi		
INC	Thu nhập		INC_001	Thu nhập dương	Nhập thu nhập dương	Hệ thống chấp nhận và xử lý dữ liệu	Okce		Thi		
			INC_002	Thu nhập âm	Nhập thu nhập âm	Hệ thống hiển thị lỗi "Giá trị không hợp lệ"	Okce		Thi		
			INC_003	Thu nhập bằng 0	Không nhập thu nhập	Hệ thống hiển thị lỗi giá trị không hợp lệ	Okce		Thi		
CS	Điểm tín dụng		CS_001	Credit Score hợp lệ	Nhập điểm hợp lệ	Hệ thống chấp nhận và xử lý	Okce		Thi		
			CS_002	Credit Score thấp	Nhập điểm < 300	Hệ thống hiển thị lỗi dưới ngưỡng cho phép	Okce		Thi		
			CS_003	Credit Score cao	Nhập điểm > 850	Hệ thống hiển thị lỗi vượt ngưỡng	Okce		Thi		
CAT	Danh mục mua		CAT_001	Category hợp lệ	Chọn danh mục hợp lệ	Hệ thống chấp nhận giá trị	Okce		Thi		
			CAT_002	Category sai	Nhập danh mục không tồn tại	Hệ thống hiển thị lỗi giá trị không hợp lệ	Okce		Thi		
BNPL	Nhà cung cấp BNPL		BNPL_001	Provider hợp lệ	Chọn provider hợp lệ	Hệ thống chấp nhận	Okce		Thi		
			BNPL_002	Provider sai	Nhập provider không tồn tại	Hệ thống hiển thị lỗi	đã giới hạn lực chọn bằng cách cho các công ty đã đc giới hạn sẵn		Thi		
PA	Số tiền mua		PA_001	Số tiền hợp lệ	Nhập số tiền dương	Hệ thống chấp nhận và xử lý	Okce		Thi		
			PA_002	Số tiền âm	Nhập số tiền âm	Hệ thống hiển thị lỗi giá trị không hợp lệ	Okce		Thi		

DEV	Thiết bị		DEV_001	Device hợp lệ	Chọn thiết bị hợp lệ	Hệ thống chấp nhận giá trị	Oke		Thì		
			DEV_002	Device sai	Nhập thiết bị không tồn tại	Hệ thống hiển thị lỗi	Luôn chọn device trong bảng lựa chọn có sẵn		Thì		
CONN	Kết nối		CONN_001	Connection hợp lệ	Chọn kết nối hợp lệ	Hệ thống chấp nhận	Oke		Thì		
			CONN_002	Connection sai	Nhập kết nối không hợp lệ	Hệ thống hiển thị lỗi	Oke		Thì		
CT	Thời gian checkout		CT_001	Checkout hợp lệ	Nhập thời gian hợp lệ	Hệ thống chấp nhận dữ liệu	Oke		Thì		
			CT_002	Checkout âm	Nhập thời gian âm	Hệ thống hiển thị lỗi giá trị không hợp lệ	Oke		Thì		
			CT_003	Checkout quá thấp	Nhập giá trị rất nhỏ	Hệ thống hiển thị cảnh báo nghi ngờ bất thường	Oke		Thì		
BR	Trình duyệt		BR_001	Browser hợp lệ	Chọn browser hợp lệ	Hệ thống chấp nhận	Oke		Thì		
			BR_002	Browser sai	Nhập browser không tồn tại	Hệ thống hiển thị lỗi	Luôn chọn trong bảng lựa chọn có sẵn		Thì		
REPAY	Trạng thái trả nợ		REPAY_001	Repayment hợp lệ	Chọn trạng thái hợp lệ	Hệ thống chấp nhận và lưu dữ liệu	Oke		Thì		
			REPAY_002	Repayment sai	Nhập trạng thái không hợp lệ	Hệ thống hiển thị lỗi giá trị không hợp lệ	Oke		Thì		
MT	Nhập số tiền phân tích		AMT_001	Số tiền hợp lệ	1. Nhập số tiền dương hợp lệ 2. Nhấn "Phân tích"	1. Số tiền được nhập vào hệ thống 2. Hệ thống xử lý và hiển thị các gói vay theo mức rủi ro (thấp, trung bình, cao)	Oke		Thì		
			AMT_002	Số tiền không hợp lệ (âm 0)	1. Nhập số tiền ≤ 0 2. Nhấn "Phân tích"	1. Giá trị không hợp lệ được nhập 2. Hệ thống hiển thị lỗi "Số tiền phải lớn hơn 0"	vẫn hiển thị kết quả là số âm		Thì		
			AMT_003	Sai định dạng dữ liệu	1. Nhập ký tự chữ hoặc ký tự đặc biệt 2. Nhấn "Phân tích"	1. Dữ liệu không hợp lệ được nhập 2. Hệ thống hiển thị lỗi định dạng	Oke		Thì		
			AMT_004	Không có kết quả phù hợp	1. Nhập số tiền hợp lệ 2. Nhấn "Phân tích" 3. Không có gói vay phù hợp	1. Số tiền được nhập 2. Hệ thống xử lý 3. Hiện thị thông báo "Không có gói vay phù hợp"	Chỉ đưa ra lựa chọn tốt nhất		Thì		

Hình 7: Bảng testcase của hệ thống

Do số lượng test case lớn, bảng kiểm thử chi tiết được lưu trữ tại đường dẫn sau để thuận tiện theo dõi:

<https://docs.google.com/spreadsheets/d/1ttNwytZKVWqK5xJTkhYQIMmofQ9SYv8VOV1Ug2VHY4/edit?usp=sharing>

PHẦN 5. HỖ TRỢ RA QUYẾT ĐỊNH, ĐẠO ĐỨC, CÂN NHẮC TRIỂN KHAI

1. Sử dụng kết quả trong quản trị

Hệ thống được xây dựng trong đề tài không chỉ dừng lại ở việc dự đoán khả năng trả nợ của khách hàng mà còn đóng vai trò như một công cụ hỗ trợ ra quyết định trong mô hình BNPL. Thông qua giao diện phân tích, người dùng có thể nhập giá trị đơn hàng và nhận được danh sách các phương án trả góp tương ứng, đi kèm với mức thanh toán hàng tháng và xác suất rủi ro. Các kết quả này được mô hình AI xử lý và lưu trữ trong cơ sở dữ liệu, giúp đảm bảo tính nhất quán và khả năng truy xuất khi cần thiết.

Từ góc độ quản trị, hệ thống cho phép doanh nghiệp đưa ra các quyết định tín dụng một cách nhanh chóng và có cơ sở dữ liệu hỗ trợ. Thay vì dựa hoàn toàn vào quy tắc cố định, doanh nghiệp có thể sử dụng xác suất dự đoán để phân loại khách hàng theo mức độ rủi ro, từ đó điều chỉnh kỳ hạn thanh toán, hạn mức tín dụng hoặc chính sách ưu đãi phù hợp. Điều này góp phần cân bằng giữa mục tiêu tăng trưởng doanh thu và kiểm soát nợ xấu trong hoạt động kinh doanh.

Ngoài ra, việc lưu trữ dữ liệu dự đoán trong bảng Predict còn giúp doanh nghiệp theo dõi lịch sử ra quyết định, từ đó phục vụ cho việc đánh giá hiệu quả mô hình và cải thiện chiến lược tín dụng theo thời gian.

2. Cân nhắc về đạo đức và rủi ro

Mặc dù hệ thống AI mang lại nhiều lợi ích, việc áp dụng trong lĩnh vực tài chính cũng đặt ra những vấn đề đạo đức và rủi ro cần được xem xét cẩn trọng. Trước hết, một trong những thách thức lớn là đảm bảo tính công bằng trong quá trình ra quyết định. Nếu dữ liệu huấn luyện chứa các yếu tố thiên lệch, mô hình có thể đưa ra những dự đoán không công bằng đối với một số nhóm khách hàng nhất định. Điều này có thể dẫn đến việc một số đối tượng bị đánh giá rủi ro cao hơn so với thực tế, từ đó ảnh hưởng đến cơ hội tiếp cận dịch vụ tài chính của họ.

Ngoài ra, tính minh bạch của hệ thống cũng là một vấn đề quan trọng. Các mô hình học máy thường hoạt động theo cơ chế phức tạp, khiến người dùng khó hiểu được nguyên nhân đằng sau các quyết định được đưa ra. Việc thiếu minh bạch có thể làm giảm mức độ tin cậy của người dùng đối với hệ thống. Do đó, cần có các biện pháp hỗ trợ giải thích kết quả ở mức phù hợp nhằm giúp người dùng hiểu rõ hơn về cách thức hoạt động của mô hình.

Bên cạnh đó, rủi ro về bảo mật và quyền riêng tư cũng cần được quan tâm, bởi hệ thống sử dụng nhiều dữ liệu nhạy cảm của khách hàng. Nếu không có các biện pháp bảo vệ phù hợp, dữ liệu có thể bị lạm dụng hoặc truy cập trái phép, gây ra những hậu quả nghiêm trọng. Cuối cùng, cần nhấn mạnh rằng hệ thống AI chỉ mang tính chất hỗ trợ, không nên thay thế hoàn toàn vai trò của con người. Trách nhiệm cuối cùng trong việc ra quyết định vẫn thuộc về nhà quản lý, nhằm đảm bảo tính kiểm soát và giảm thiểu các rủi ro tiềm ẩn.

3. Khả thi và khả năng mở rộng

Về mặt triển khai, hệ thống được xây dựng với các công nghệ tương đối phổ biến như PyQt6 cho giao diện người dùng và MongoDB cho lưu trữ dữ liệu giúp đảm bảo tính linh hoạt và dễ dàng phát triển trong môi trường thực tế. Kiến trúc gồm ba bảng chính (user, information, predict) giúp tổ chức dữ liệu rõ ràng, hỗ trợ tốt cho việc mở rộng chức năng trong tương lai.

Hệ thống hiện tại có thể hoạt động như một ứng dụng độc lập trên máy tính cá nhân, phù hợp cho mục đích nghiên cứu và thử nghiệm mô hình. Trong tương lai, hoàn toàn có thể mở rộng sang dạng web application hoặc tích hợp vào các nền tảng thương mại điện tử để phục vụ lượng người dùng lớn hơn.

Ngoài ra, mô hình AI có thể được cải thiện bằng cách cập nhật thêm dữ liệu thực tế, bổ sung các biến liên quan đến lịch sử tín dụng dài hạn hoặc hành vi tài chính theo thời gian. Việc này sẽ giúp nâng cao độ chính xác của dự đoán và tăng giá trị ứng dụng trong môi trường kinh doanh thực tế.

PHẦN 6. KẾT LUẬN VÀ LỘ TRÌNH DỰ ÁN

Đề tài đã xây dựng thành công một hệ thống hỗ trợ ra quyết định trong mô hình Buy Now Pay Later (BNPL), dựa trên sự kết hợp giữa phân tích dữ liệu và ứng dụng trí tuệ nhân tạo. Hệ thống được thiết kế với mục tiêu dự đoán xác suất vỡ nợ của khách hàng dựa trên các đặc trưng về tài chính, hành vi và nhân khẩu học, từ đó đề xuất các phương án trả góp phù hợp với từng cá nhân. Không chỉ dừng lại ở việc xây dựng mô hình dự đoán, đề tài còn tích hợp mô hình này vào một hệ thống hoàn chỉnh bao gồm giao diện người dùng và cơ sở dữ liệu, giúp chuyển hóa kết quả phân tích thành các đề xuất mang tính ứng dụng thực tế. Nhờ đó, hệ thống không chỉ nâng cao trải nghiệm người dùng thông qua việc cá nhân hóa phương án thanh toán, mà còn hỗ trợ doanh nghiệp đưa ra các quyết định tín dụng một cách nhanh chóng, nhất quán và có cơ sở dữ liệu rõ ràng.

Xét về giá trị kinh doanh, hệ thống mang lại lợi ích đáng kể trong việc quản lý và kiểm soát rủi ro tín dụng. Thông qua việc định lượng xác suất vỡ nợ dưới dạng một chỉ số cụ thể, doanh nghiệp có thể phân loại khách hàng theo mức độ rủi ro và điều chỉnh chính sách cấp tín dụng một cách linh hoạt. Đồng thời, việc đề xuất các phương án trả góp tối ưu giúp cân bằng giữa khả năng chi trả của khách hàng và mức độ rủi ro chấp nhận được của doanh nghiệp, từ đó góp phần nâng cao tỷ lệ hoàn trả và giảm thiểu nợ xấu. Trong bối cảnh thị trường tài chính số ngày càng cạnh tranh và yêu cầu cao về quản trị rủi ro, việc ứng dụng các hệ thống AI như vậy không chỉ giúp doanh nghiệp tối ưu hiệu quả hoạt động mà còn tạo ra lợi thế cạnh tranh bền vững.

Trong tương lai, dự án có thể được phát triển theo một lộ trình rõ ràng và khả thi. Ở giai đoạn đầu, trọng tâm sẽ là nâng cao chất lượng mô hình thông qua việc mở rộng và làm giàu dữ liệu, đồng thời tối ưu hóa thuật toán nhằm cải thiện độ chính xác và khả năng tổng quát hóa. Tiếp theo, hệ thống có thể được mở rộng sang nền tảng web hoặc triển khai dưới dạng dịch vụ API, cho phép tích hợp linh hoạt với các nền tảng thương mại điện tử hoặc hệ thống tài chính hiện có. Ở giai đoạn hoàn thiện, hệ thống có thể được triển khai trong môi trường thực tế với dữ liệu người dùng thật, kết hợp với các cơ chế giám sát, đánh giá hiệu suất và cập nhật mô hình liên tục (continuous learning) để đảm bảo tính ổn định và khả năng thích ứng với sự thay đổi của hành vi khách hàng theo thời gian.

Tổng thể, đề tài không chỉ mang ý nghĩa học thuật trong việc ứng dụng các phương pháp học máy vào bài toán tài chính, mà còn thể hiện rõ tiềm năng triển khai trong thực tiễn. Hệ thống là minh chứng cho vai trò ngày càng quan trọng của trí tuệ nhân tạo trong việc hỗ trợ ra quyết định, đặc biệt trong các lĩnh vực đòi hỏi sự cân bằng giữa trải nghiệm người dùng và kiểm soát rủi ro như tài chính số. Qua đó, đề tài góp phần làm rõ cách thức mà AI có thể được tích hợp vào quy trình kinh doanh để tạo ra giá trị thực tiễn, hướng tới việc xây dựng các hệ thống thông minh, hiệu quả và bền vững hơn trong tương lai.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Zhi Zheng Kang, Sin Yin Teh, Samuel Yong Guang Tan và Wei Chien Ng, "Loan Default Prediction Using Machine Learning Algorithms" , <https://journals.mmupress.com/index.php/jiwe/article/view/1680> , 2025
- [2] Sakshi Udavant, “Buy Now, Pay Later (BNPL): What It Is, How It Works, Pros and Cons”, <https://www.investopedia.com/buy-now-pay-later-5182291> , 2025
- [3] Kexin Zhao¹ , Bo Wang¹ , Cuiying Zhao¹ , Tongyao Wan¹, “Multi-Treatment-DML: Causal Estimation for Multi-Dimensional Continuous Treatments with Monotonicity Constraints in Personal Loan Risk Optimization”, <https://arxiv.org/pdf/2508.02183> , 2025

PHỤ LỤC

ĐẠI HỌC QUỐC GIA TP.HCM

TRƯỜNG ĐẠI HỌC KINH TẾ LUẬT

Môn học: Giải pháp AI trong kinh doanh và quản lý

-----o0o-----

BÁO CÁO QUÁ TRÌNH LÀM VIỆC NHÓM

I/ Danh sách thành viên:

1. Phan Ngọc Linh - K244020159
2. Nguyễn Điền Xuân Nghi - K244060730
3. Bùi Vũ Khánh Phương - K244020187 (Nhóm trưởng)
4. Mai Ngọc Thi - K244060743
5. Nguyễn Thị Ngọc Tú - K244020198

II/ Ghi nhật ký quá trình thực hiện đồ án

Trong quá trình thực hiện đồ án, nhóm bắt đầu triển khai vào ngày 07/03/2026 với việc trao đổi và thống nhất giữ nguyên chủ đề BNPL, không thay đổi bài toán mà chỉ bổ sung dataset và khai thác sâu hơn. Bạn Thi là người đề xuất ý tưởng chính, tìm các dataset từ nhiều nguồn và tiến hành thử nghiệm, các thành viên khác tham gia góp ý và lựa chọn.

Từ ngày 07/03 đến 09/03, nhóm test nhiều dataset và model, sau đó chọn được dataset phù hợp và sử dụng kết quả mô hình tốt nhất tại thời điểm đó. Ngày 14/03, nhóm hoàn thành bài thực hành và tiến hành phân công công việc gồm: Ngọc Tú đề xuất flow cho hệ thống, Thi thực hiện code web (backend), Ngọc Linh thiết kế frontend, Khánh Phương thực hiện test và xây dựng test case, Xuân Nghi viết báo cáo kết quả và nội dung mô hình. Ngày 16/03, nhóm xác định deadline cho từng phần và điều chỉnh lại để phù hợp với hạn nộp ngày 29/03, đồng thời thực hiện song song giữa viết báo cáo và làm kỹ thuật. Ngày 21/03, nhóm thay đổi thứ tự công việc, ưu tiên làm backend trước, sau đó mới đến frontend và test, trong khi báo cáo vẫn được thực hiện song song.

Ngày 22/03, sau khi web được xây dựng bằng PyQt6, test case được xây dựng dựa trên dataset đã sử dụng. Trong cùng ngày, nhóm xem giao diện web và thống nhất giữ giao diện đơn giản. Từ ngày 22/03 đến 24/03, test case được hoàn thiện dần, đồng thời các thành viên cập nhật nội dung vào báo cáo và bổ sung hình ảnh, mô tả. Ngày 23/03, nhóm chỉnh sửa lại workflow và nội dung liên quan. Ngày 24/03, nhóm xác định yêu cầu nộp bài và chuẩn bị nội dung cho báo cáo. Từ ngày 26/03 đến 27/03, nhóm tiếp tục hoàn thiện test case, hoàn chỉnh báo cáo và kiểm tra độ trùng lặp, sau đó phân công nội dung làm slide cho từng thành viên để chuẩn bị thuyết trình.

III/ Đánh giá đóng góp cá nhân

HỌ TÊN	MÔ TẢ CÔNG VIỆC	MỨC ĐỘ HOÀN THÀNH	% ĐÓNG GÓP	NHẬN XÉT CỦA NHÓM
Mai Ngọc Thi - K244060743	- Đề xuất ý tưởng và định hướng bài toán - Tìm và test dataset, xây dựng model - Code web (backend), hoàn thiện sản phẩm - Hỗ trợ chạy test và xử lý kỹ thuật	Hoàn thành tốt nhiệm vụ, có phần trễ tiến độ ở một số giai đoạn nhưng đã hoàn thiện đầy đủ	100%	Đóng vai trò chính trong phần kỹ thuật, tham gia đầy đủ, hỗ trợ các thành viên khác khi cần.
Nguyễn Thị Ngọc Tú - K244020198	- Đề xuất và xây dựng flow hệ thống - Thiết kế workflow - Chỉnh sửa nội dung sơ đồ	Hoàn thành nhiệm vụ, có chỉnh sửa theo góp ý	100%	Thực hiện đúng phần được giao, tiếp thu và điều chỉnh theo góp ý của nhóm
Phan Ngọc Linh - K244020159	- Tìm các tài liệu nghiên cứu trước đó - Thiết kế frontend cho web - Góp ý giao diện	Hoàn thành tốt nhiệm vụ, đúng tiến độ	100%	Thực hiện đúng phần được giao, tiếp thu và điều chỉnh theo góp ý của nhóm
Bùi Vũ Khánh Phương - K244020187	- Xây dựng test case - Thực hiện test sản phẩm - Tổng hợp bảng test	Hoàn thành nhiệm vụ, có bổ sung và chỉnh sửa trong quá trình làm	100%	Làm việc nghiêm túc, có cập nhật và điều chỉnh theo tiến độ chung
Nguyễn Điền Xuân Nghi - K244060730	- Viết báo cáo - Tổng hợp nội dung từ các thành viên - Kiểm tra trùng lặp văn - Phân chia nội dung slide	Hoàn thành tốt nhiệm vụ, đúng tiến độ	100%	Làm việc ổn định, đảm bảo tiến độ và tổng hợp nội dung đầy đủ

IV/ Tổng kết

Trong quá trình thực hiện, nhóm bắt đầu triển khai khá trễ nên phần lớn công việc được thực hiện trong thời gian ngắn trước deadline. Việc phối hợp giữa các thành viên chủ yếu thông qua trao đổi online, có phân công nhiệm vụ rõ ràng theo từng giai đoạn nhưng chưa được thiết lập chi tiết ngay từ đầu. Một số phần công việc phụ thuộc vào thành viên phụ trách kỹ thuật nên tiến độ chung bị ảnh hưởng khi phần này chưa hoàn thành. Các thành viên đều tham gia và thực hiện nhiệm vụ được giao, tuy nhiên việc theo dõi tiến độ và kiểm soát thời gian chưa chặt chẽ, dẫn đến việc phải điều chỉnh kế hoạch nhiều lần. Trong quá trình làm việc cũng phát sinh một số vấn đề như thiếu kinh nghiệm về AI, lỗi kỹ thuật, nội dung chưa đồng bộ và phải chỉnh sửa ở giai đoạn cuối. Nhóm xử lý bằng cách thu hẹp phạm vi, tập trung vào các phần chính và làm song song nhiều nội dung để kịp tiến độ.

Về kết quả đề tài, nhóm đã hoàn thành được các nội dung cơ bản gồm xây dựng model, triển khai web và viết báo cáo. Sản phẩm có thể chạy và thể hiện được chức năng chính theo yêu cầu. Tuy nhiên, một số phần chưa được hoàn thiện đầy đủ như tối ưu giao diện, mở rộng chức năng và cải thiện độ chính xác của mô hình. Nội dung trình bày và một số chi tiết nhỏ vẫn cần chỉnh sửa thêm nếu có thêm thời gian. Tổng thể, đề tài đạt ở mức hoàn thành yêu cầu cơ bản.